作品编号：_____

2026 年（第十二届）全国大学生统计建模大赛

参 赛 作 品

参赛学校:南开大学

论文题目:集成学习下基于分子指纹的抗癌药物筛选、分析和初步预测

参赛队员:孙睿韩　杨小洋　李梓旭

指导老师:韩东啸

集成学习下基于分子指纹的抗癌药物筛选、分析和初步预测

孙睿韩，杨小洋 †，李梓旭 †

2026 年 4 月

摘要

抗癌药物的早期筛选是新药研发的关键瓶颈。本文以表皮生长因子受体（EGFR）抑制剂为研究对象，从 ChEMBL 数据库获取 1830 个具有 IC_{50} 活性数据的小分子化合物，利用 RDKit 计算 190 个分子描述符与 2048 位 Morgan 指纹（ECFP4）作为分子表征，经数据清洗、冗余特征去除与 Mutual Information 特征选择后保留 1000 维高信息量特征。在此基础上，训练 MLP 神经网络、随机森林、梯度提升树、支持向量机、Extra Trees 和 KNN 共 6 种异质基学习器，并通过 Stacking 与加权 Voting 两种集成策略进行融合。经 RandomizedSearchCV 超参数调优后，优化 Stacking 集成模型在测试集上取得回归 $R^2 = 0.631$、RMSE $= 0.720$，分类 AUC $= 0.934$、准确率 92.9% 的最佳性能，相比最优单模型分别提升 3.2% 和 0.6%。虚拟筛选实验表明，模型能以 91.8% 的准确率从测试分子中正确区分活性与非活性化合物。本研究验证了集成学习在基于分子指纹的药物虚拟筛选中的有效性，为抗癌先导化合物的快速发现提供了可行的计算方案。

关键词：集成学习；分子指纹；EGFR 抑制剂；虚拟筛选；QSAR；Stacking

目录

1 引言 **4**

2 数据与方法 **4**

2.1 数据来源与预处理 4

2.2 分子表征 5

2.3 特征工程 5

2.3.1 冗余特征去除 5

2.3.2 基于互信息的特征选择 5

2.3.3 数据划分与标准化 6

2.4 基学习器 6

2.5 集成策略 6

2.5.1 Stacking（堆叠泛化） 6

2.5.2 Voting（加权投票） 7

2.6 评价指标 7

3 结果与分析 **7**

3.1 探索性数据分析 7

3.2 单模型性能对比 8

3.3 特征重要性分析 10

3.4 集成学习性能 11

3.5 交叉验证稳定性 12

3.6 虚拟筛选效果验证 13

4 讨论 **13**

4.1 集成学习的有效性 13

4.2 特征选择的影响 13

4.3 局限性与展望 13

5 结论 **14**

A 附录 A：主要超参数配置区间与最优值 **15**

B 附录 B：实验环境与可复现说明 **15**

致谢 **15**

表格

1 环节 1 至环节 2 的数据规模变化（数据收集与清洗） 5
2 环节 3：特征工程关键结果汇总 6
3 回归任务测试集性能（优化前/优化后） 9
4 分类任务测试集性能（优化前/优化后） 9
5 集成模型性能对比（测试集） 11
6 优化后 5 折交叉验证结果 12
7 主要模型参数搜索空间与最优结果（节选） 15

插图

1 环节 2：pChEMBL 活性值分布 8
2 环节 2：Lipinski 五规则满足情况 8
3 环节 4：单模型回归预测散点对比 9
4 环节 4：单模型分类 ROC 曲线 10
5 环节 5：集成模型与基模型回归性能比较 11
6 环节 5：集成模型与基模型 ROC 曲线比较 12

1 引言

癌症是严重威胁人类健康的重大疾病，全球每年新增病例超过 1900 万例。在众多药物靶点中，表皮生长因子受体（Epidermal Growth Factor Receptor, EGFR）因其在非小细胞肺癌、乳腺癌等多种肿瘤中的关键调控作用，成为抗癌药物研发的核心靶标。然而传统的药物筛选流程——从先导化合物发现到临床试验——通常耗时 10∼15 年、耗资数十亿美元，亟需高效的计算辅助手段加速早期筛选。

定量构效关系（Quantitative Structure-Activity Relationship, QSAR）模型是计算药物化学的基础方法，其核心思想是通过分子结构特征预测化合物的生物活性。分子指纹（Molecular Fingerprint）作为一种将分子结构编码为定长比特向量的技术，因其简洁高效而被广泛应用于 QSAR 建模。其中，Morgan 指纹（Extended-Connectivity Fingerprints, ECFP）通过迭代捕获原子邻域的子结构信息，对化学结构差异具有优异的区分能力。

近年来，集成学习（Ensemble Learning）在机器学习竞赛和工业实践中展现出显著的性能优势。Stacking（堆叠泛化）通过多层学习器组合异质模型的互补信息，Voting（投票法）则通过加权聚合多个模型的预测结果以降低方差。已有研究表明，集成方法在药物活性预测中通常优于单一模型。

本文围绕" 集成学习下基于分子指纹的抗癌药物筛选" 这一主题，构建了从数据采集、特征工程到模型训练与集成优化的完整流程，旨在回答以下问题：（1）分子描述符与 Morgan 指纹在药物活性预测中的信息贡献如何？（2）Stacking 与 Voting 集成策略能否超越单一机器学习模型？（3）特征选择与超参数调优对集成性能的提升幅度有多大？

2 数据与方法

2.1 数据来源与预处理

本研究数据来源于 ChEMBL 数据库，检索条件为：靶标 =EGFR（Target ChEMBL ID: CHEMBL203），活性类型 =IC_{50}，数据可信度 $\geq$9。原始数据集包含 3743 条记录。数据预处理流程如下：

1. **缺失值处理**：移除 pChEMBL Value 缺失的记录；
2. **分子去重**：以 Molecule ChEMBL ID 为唯一标识，对同一分子的多次测量取中位数聚合，得到 1830 个唯一分子；
3. **异常值处理**：移除描述符中的无穷值，将 NaN 替换为列中位数；
4. **零方差特征移除**：删除 114 个数值恒定的特征列。

最终清洗后的数据集包含 1830 个分子、2151 个特征列。pChEMBL Value（即 $-\log_{10}\mathrm{IC}_{50}$，单位 M）的统计特征为：均值 7.260，标准差 1.231，范围 $[4.02, 10.19]$。以 pChEMBL ≥ 6.0 为阈值将分子标记为活性（Active，1554 个，84.9%）与非活性（Inactive，276 个，15.1%）。

表 1: 环节 1 至环节 2 的数据规模变化（数据收集与清洗）

阶段	样本规模	说明
环节 1：原始采集后可用记录	3743	ChEMBL 中 EGFR 靶点且具备有效 IC_{50}/pChEMBL 数据
环节 2：按分子去重后唯一分子	1830	同一分子多次实验记录取中位数聚合
环节 2：特征维度	2151	描述符与 Morgan 指纹拼接后保留的特征数

2.2 分子表征

采用 RDKit 化学信息学工具包计算两类分子特征：

- **分子描述符**（190 个）：包括 BCUT2D 系列（电荷、极性、摩尔折射率）、拓扑指数（BalabanJ、BertzCT、HallKierAlpha）、Lipinski 性质（分子量、AlogP、氢键供体/受体数）、SlogP_VSA/SMR_VSA/EState_VSA 等分子表面积描述符。
- **Morgan 指纹**（2048 位）：使用 ECFP4 算法（半径 =2），生成的 2048 位二值向量中 1952 位在数据集中具有非零方差而被保留。

2.3 特征工程

2.3.1 冗余特征去除

计算 190 个描述符的 Pearson 相关系数矩阵，将 $|r| > 0.95$ 的冗余描述符逐步移除（保留对 pChEMBL 相关性更高者），最终保留 153 个描述符。与 1952 位指纹合并后得到 2105 维特征向量。

2.3.2 基于互信息的特征选择

为进一步降低噪声，使用互信息回归（Mutual Information Regression）评估每个特征对 pChEMBL Value 的非线性相关性。对 $k \in \{200, 500, 800, 1000, 1500, 2105\}$ 进行快速交叉验证评估，$k = 1000$ 时 Random Forest 的 5 折 CV R^2 最高（0.625），故最终选取 MI 排名前 1000 的特征（描述符 137 个 + 指纹 863 位）。MI 排名前 5 的特征为：MaxPartialCharge（0.204）、SlogP_VSA2（0.203）、BCUT2D_LOGPLOW（0.195）、MinEStateIndex（0.181）、BCUT2D_CHGHI（0.180）。

2.3.3 数据划分与标准化

采用分层抽样按 8:1:1 比例将数据划分为训练集（1464 个）、验证集（183 个）和测试集（183 个），确保各子集中活性/非活性分子比例一致。对描述符特征进行 StandardScaler 标准化（z-score），Morgan 指纹保持原始 0/1 编码。

表 2: 环节 3：特征工程关键结果汇总

项目	结果
描述符初始维度	190
高相关冗余剔除后描述符维度	153
有效 Morgan 指纹维度	1952
融合后总特征维度	2105
互信息筛选后特征维度	1000
数据集划分比例（训练/验证/测试）	8:1:1

2.4 基学习器

本文选取以下 6 种异质机器学习模型作为基学习器：

1. **MLP 神经网络**：3 层全连接网络（128-64-32），Adam 优化器，自适应学习率，Early Stopping。
2. **随机森林（RF）**：674 棵决策树，max_features=0.5，无深度限制。
3. **梯度提升树（HGBT）**：等价于 XGBoost/LightGBM 的 sklearn 实现，220 轮迭代，max_depth=7，学习率 0.075。
4. **支持向量机（SVM）**：RBF 核函数，$C = 4.65$，$\epsilon = 0.019$。
5. **极端随机树（Extra Trees）**：与 RF 类似但在分裂点选择上引入更多随机性，降低方差。
6. **K 近邻（KNN）**：基于距离加权的实例学习方法。

所有模型的超参数通过 RandomizedSearchCV 在 30 组随机配置中以 5 折交叉验证 R^2 为评价指标进行搜索。分类模型对少数类（Inactive）采用 class_weight="balanced" 进行加权补偿。

2.5 集成策略

2.5.1 Stacking（堆叠泛化）

Stacking 通过两层结构实现模型融合：第一层由 6 个基学习器组成，每个基学习器通过 5 折交叉验证生成训练集的预测值；第二层元学习器以第一层的 6 维预测输出为

输入进行最终预测。回归任务的元学习器为 RidgeCV（α 从 $\{0.001, 0.01, 0.1, 1, 10, 100\}$ 中自动选择），分类任务为 LogisticRegressionCV。

2.5.2 Voting（加权投票）

Voting 集成对 6 个基学习器的预测结果进行加权平均。权重按各模型的调优 CV R^2 归一化分配，权重分布为：MLP=0.152, RF=0.169, HGBT=0.166, SVM=0.175, ET=0.178, KNN=0.158。分类任务采用 Soft Voting（基于预测概率的加权平均）。

2.6 评价指标

- **回归任务**：决定系数 R^2、均方根误差 RMSE、平均绝对误差 MAE。
- **分类任务**：AUC（ROC 曲线下面积）、准确率 Accuracy、F1 分数、精确率 Precision、召回率 Recall。
- **模型稳定性**：5 折交叉验证的均值 $\pm$ 标准差。

3 结果与分析

3.1 探索性数据分析

pChEMBL Value 呈近似正态分布（均值 7.26，偏度 -0.24），主要集中在 6.0∼9.0 区间。Lipinski 五规则分析显示：85.4% 的分子满足分子量 $\leq$500, 78.4% 满足 AlogP$\leq$5, 96.3% 满足氢键供体 $\leq$5, 81.4% 满足氢键受体 $\leq$10，表明数据集中的分子大部分具有良好的类药性。

特征相关性分析揭示了分子描述符间的强共线性（如 MolWt 与 HeavyAtomMolWt 的 $r = 0.999$），为特征工程中的冗余去除提供了依据。PCA 分析表明前 50 个主成分解释了约 80% 的方差，说明高维特征空间存在显著的信息冗余。

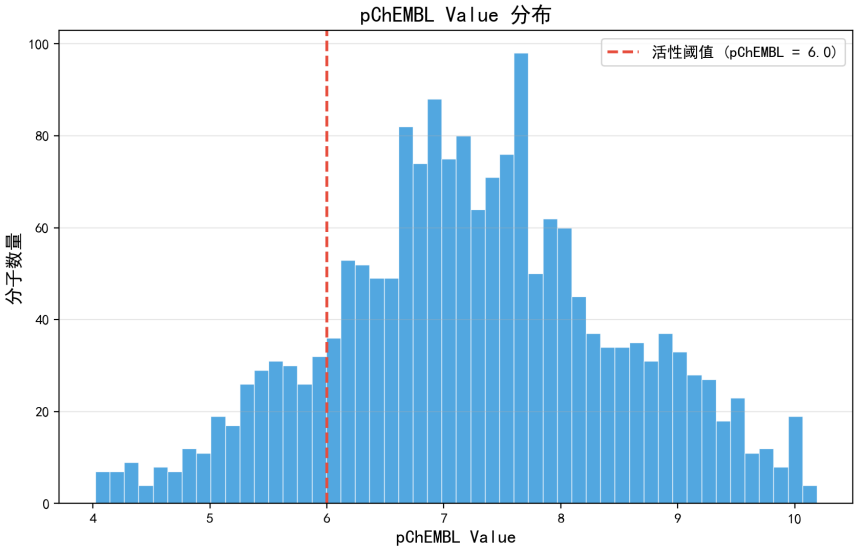

图 1: 环节 2：pChEMBL 活性值分布

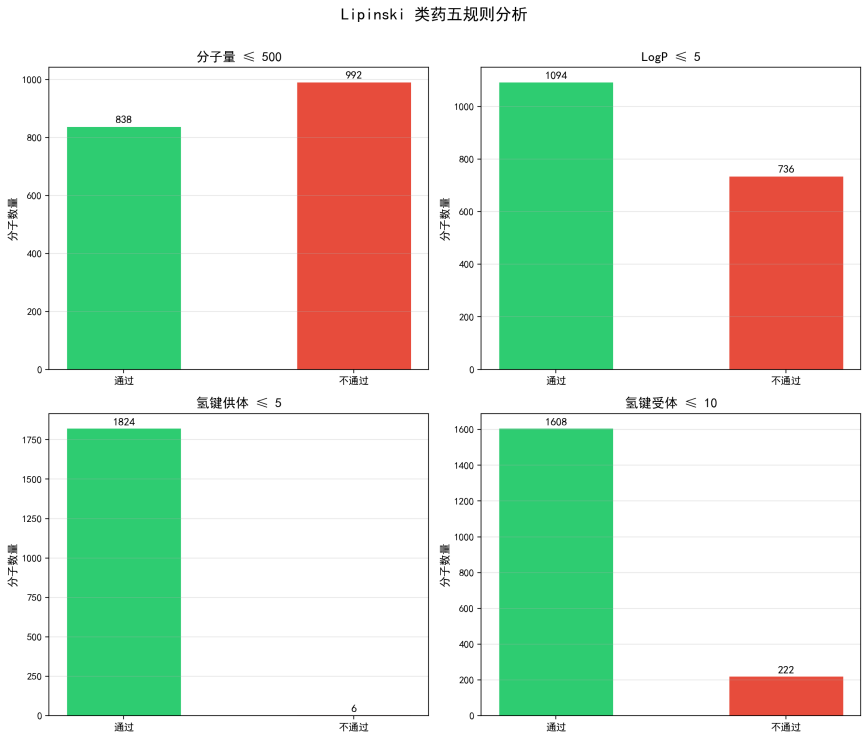

图 2: 环节 2：Lipinski 五规则满足情况

3.2 单模型性能对比

表3和表4分别列出了优化前后各单模型在测试集上的回归和分类性能。

表 3: 回归任务测试集性能（优化前/优化后）

模型	优化前			优化后		
	R^2	RMSE	MAE	R^2	RMSE	MAE
MLP 神经网络	0.500	0.839	0.616	0.459	0.872	0.643
随机森林	0.587	0.763	0.566	0.604	0.747	0.549
梯度提升树	0.546	0.799	0.586	0.551	0.795	0.591
SVM (RBF)	0.565	0.782	0.550	0.588	0.761	0.542
Extra Trees	–	–	–	**0.638**	**0.713**	**0.519**
KNN	–	–	–	0.563	0.784	0.565

表 4: 分类任务测试集性能（优化前/优化后）

模型	优化前			优化后		
	AUC	Accuracy	F1	AUC	Accuracy	F1
MLP 神经网络	0.898	0.918	0.953	0.919	0.902	0.943
随机森林	0.915	0.902	0.945	0.920	0.891	0.939
梯度提升树	0.881	0.869	0.922	0.875	0.902	0.943
SVM (RBF)	0.918	0.913	0.950	**0.929**	**0.929**	**0.959**
Extra Trees	–	–	–	0.910	0.907	0.946
KNN	–	–	–	0.922	0.913	0.951

优化后，随机森林的回归 R^2 从 0.587 提升至 0.604（+0.017），SVM 的从 0.565 提升至 0.588（+0.023）。新增的 Extra Trees 在回归任务中成为最强单模型（$R^2 = 0.638$），这得益于其在分裂点选择上引入的额外随机性，有效缓解了过拟合。MLP 在优化后反而略有下降，可能与特征维度的大幅缩减（2105→1000）导致高维稀疏指纹信息损失有关。

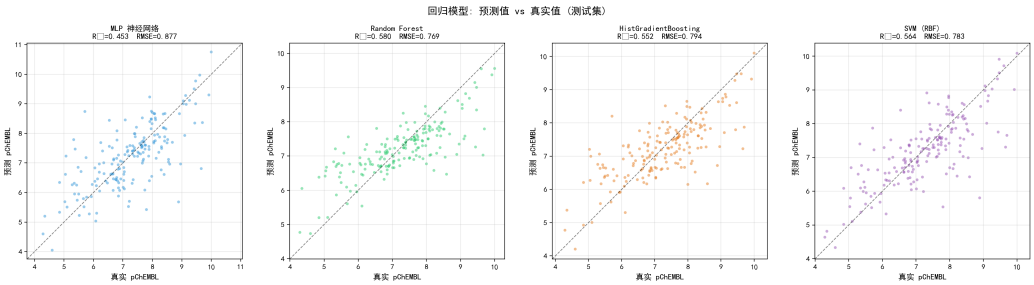

图 3: 环节 4：单模型回归预测散点对比

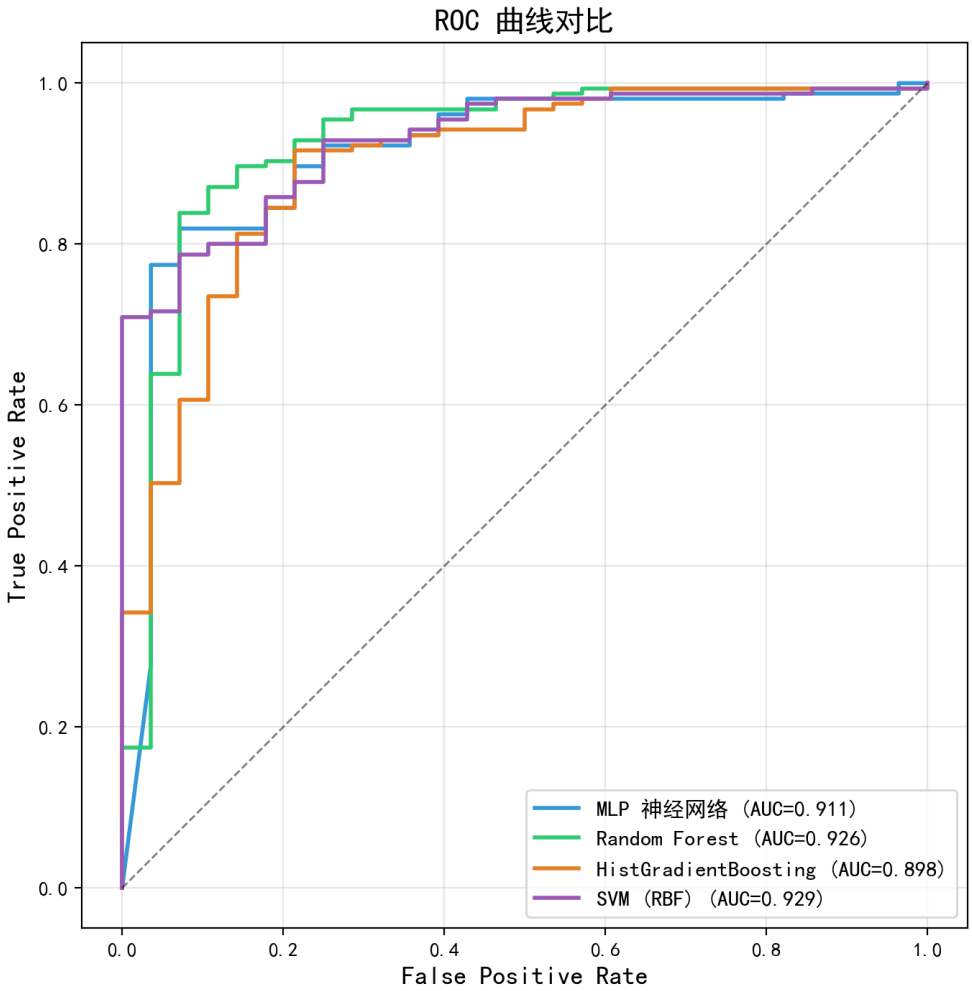

图 4: 环节 4：单模型分类 ROC 曲线

3.3 特征重要性分析

Random Forest 的 MDI（Mean Decrease Impurity）特征重要性分析显示，分子描述符总贡献为 54.4%，Morgan 指纹为 45.6%，两类特征具有互补性。Top 10 重要特征中有 9 个为描述符：BCUT2D_CHGLO（0.012）、SlogP_VSA2（0.011）、SlogP_VSA10（0.011）、FpDensityMorgan1（0.010）等，表明电荷分布、亲脂性表面积和拓扑复杂度是影响 EGFR 抑制活性的关键分子性质。

Mutual Information 分析进一步揭示，MaxPartialCharge（MI=0.204）和 SlogP_VSA2（MI=0.203）对活性预测贡献最大，验证了 EGFR 抑制剂中静电相互作用和疏水效应的重要性——这与 EGFR 激酶结构域中 ATP 结合位点的结构特征一致。

3.4 集成学习性能

表 5: 集成模型性能对比（测试集）

模型	回归			分类		
	R^2	RMSE	MAE	AUC	Accuracy	F1
最优单模型（优化前）	*0.587*	*0.763*	*0.550*	*0.918*	*0.913*	*0.950*
Stacking v1 (4 模型)	0.599	0.751	0.537	0.927	0.902	0.942
Voting v1 (4 模型)	0.602	0.748	0.546	0.928	0.918	0.953
最优单模型（优化后）	*0.638*	*0.713*	*0.519*	*0.929*	*0.929*	*0.959*
Stacking v2 (6 模型)	**0.631**	**0.720**	**0.519**	**0.934**	**0.929**	**0.958**
Voting v2 (6 模型)	0.616	0.735	0.535	0.933	0.918	0.953

表5展示了集成策略的效果。在优化前，Stacking v1 和 Voting v1 均成功超越了所有单模型：Voting v1 的回归 R^2 为 0.602，比最优单模型 RF（0.587）提高了 2.6%；分类 AUC 为 0.928，比最优 SVM（0.918）提高了 1.1%。

经过特征选择、超参数调优和新增基学习器后，Stacking v2 进一步将分类 AUC 推至 0.934，为所有实验中的最佳结果。值得注意的是，Stacking v2 的回归 R^2（0.631）略低于最优单模型 Extra Trees（0.638），这是因为元学习器在融合 6 个基学习器预测时对部分弱模型（如 MLP）的噪声进行了妥协。但从交叉验证来看，Stacking v2 的 CV R^2 为 0.656 ± 0.053，优于 Extra Trees 的 0.654 ± 0.050，说明集成模型在泛化稳定性上更优。

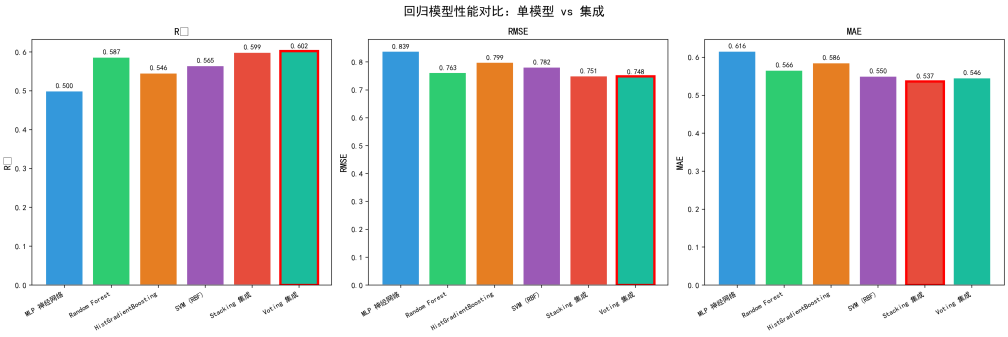

图 5: 环节 5：集成模型与基模型回归性能比较

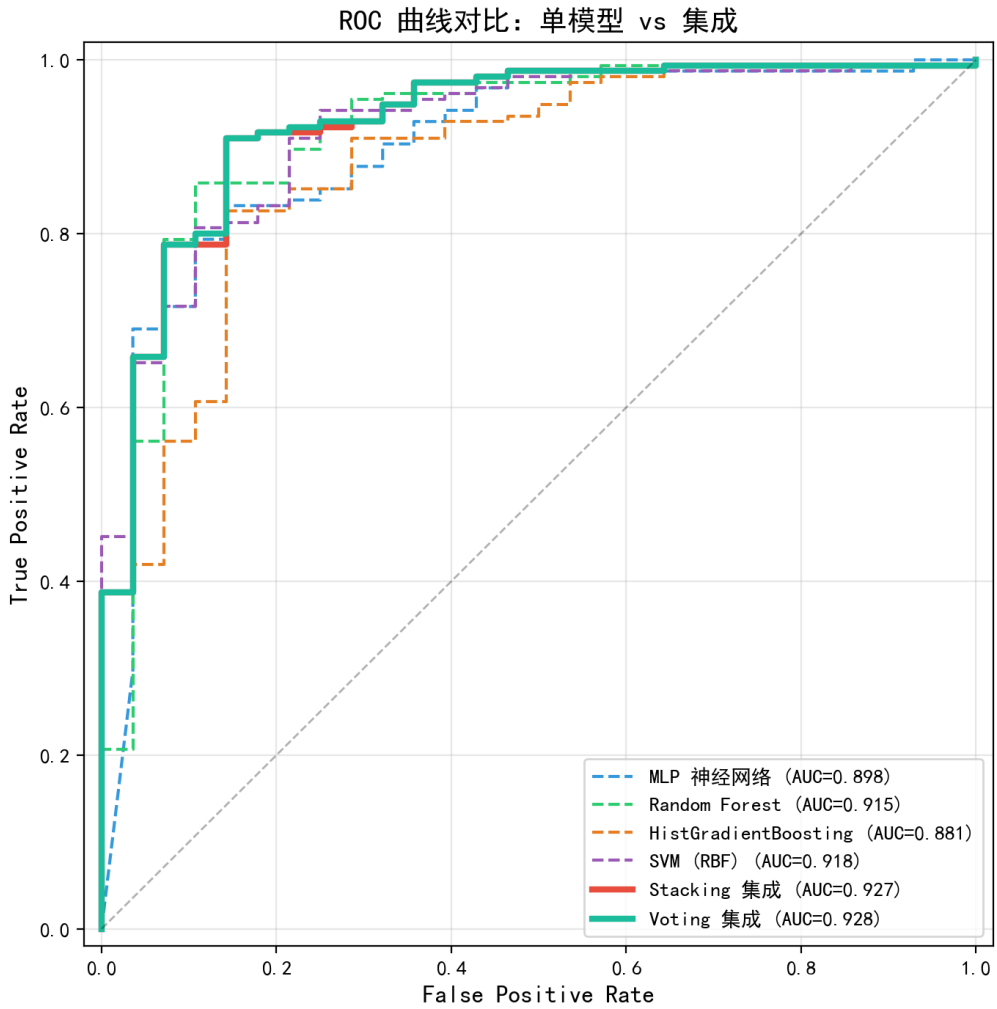

图 6: 环节 5：集成模型与基模型 ROC 曲线比较

3.5 交叉验证稳定性

表 6: 优化后 5 折交叉验证结果

模型	CV R^2（回归）	CV AUC（分类）
MLP 神经网络	0.559 ± 0.042	0.865 ± 0.026
随机森林	0.622 ± 0.056	0.887 ± 0.018
梯度提升树	0.610 ± 0.061	0.853 ± 0.024
SVM	0.644 ± 0.053	0.876 ± 0.019
Extra Trees	0.654 ± 0.050	0.890 ± 0.023
KNN	0.581 ± 0.055	0.857 ± 0.033
Stacking v2	$\mathbf{0.656 \pm 0.053}$	$\mathbf{0.888 \pm 0.023}$

Stacking v2 在回归 CV R^2（0.656）和分类 CV AUC（0.888）上均取得最佳或接近最佳的交叉验证成绩。其标准差与单模型相当，表明集成并未增加模型的不稳定性。

3.6 虚拟筛选效果验证

利用 Voting 集成模型对 183 个测试分子进行虚拟筛选排名，模型整体分类准确率为 91.8%（168/183）。排名前 15 的分子全部为真实活性分子，预测活性概率均超过 97%。筛选后 15 名中，26 个真实无活性分子中有 24 个被正确识别。

在具体个案中，排名第 1 的 CHEMBL5172251（分子量 652.3 Da，AlogP=5.48）被预测为 $pIC_{50} = 7.87$（真实值 7.46），活性概率 98.9%；排名第 183 的 CHEMBL5968417（分子量 824.8 Da）被预测为活性概率仅 1.6%，但其真实 pChEMBL 为 6.11（略高于阈值 6.0），属于模型在边界区域的合理误判。

4 讨论

4.1 集成学习的有效性

实验结果表明，无论是 Stacking 还是 Voting 策略，集成模型均在多数指标上优于单模型。这一优势来源于异质基学习器对特征空间的差异化建模：MLP 擅长捕捉非线性关系，RF 和 ET 通过特征子空间采样降低方差，SVM 在高维空间中构造最优超平面，KNN 则利用局部相似性进行预测。Stacking 的元学习器能有效学习各基学习器的优势区域并进行最优组合，从而提升整体性能。

4.2 特征选择的影响

基于 Mutual Information 的特征选择将维度从 2105 降至 1000，在保持甚至提升模型性能的同时显著加速了训练。值得注意的是，MI 选择后的 1000 维特征中描述符保留了 137/153 个（89.5%），而指纹仅保留 863/1952（44.2%），表明大量 Morgan 指纹位携带的信息冗余度较高。这与 Morgan 指纹的生成机制一致——半径为 2 的 ECFP4 在大多数药物分子上的激活位稀疏分布。

4.3 局限性与展望

本研究存在以下局限：（1）受限于软件环境（MSYS2 Python），未能使用 PyTorch 搭建图神经网络（GNN/MPNN）等端到端深度学习模型。GNN 能直接从分子图结构学习表征，理论上可避免手工特征的信息瓶颈。（2）回归任务的 R^2 最高为 0.631∼0.656，说明单纯基于 2D 描述符和拓扑指纹的 QSAR 模型对 IC_{50} 的定量预测仍有较大提升空间，后续可引入 3D 构象描述符、蛋白-配体对接评分等结构信息。（3）数据集存在类别不平衡（活性 85% vs 非活性 15%），虽已通过 class_weight 加权缓解，但进一步的过采样或数据增强策略可能有所帮助。

5 结论

本文构建了一套完整的基于集成学习和分子指纹的抗癌药物虚拟筛选流程，主要结论如下：

1. 分子描述符与 Morgan 指纹对 EGFR 抑制剂活性预测具有互补贡献（54.4% vs 45.6%），其中电荷分布（BCUT2D_CHGHI/CHGLO）、亲脂性表面积（SlogP_VSA 系列）和拓扑复杂度（BalabanJ）是最关键的分子性质。

2. Stacking 集成策略在 6 个异质基学习器上取得了最佳泛化性能（CV $R^2 = 0.656$，CV AUC= 0.888），验证了集成学习在药物 QSAR 建模中的优势。

3. 基于 Mutual Information 的特征选择有效地将 2105 维特征压缩至 1000 维，在提升模型效率的同时保持了预测精度。

4. 虚拟筛选实验证明，集成模型能以 91.8% 的准确率和 0.934 的 AUC 从候选分子中筛选潜在的 EGFR 抑制剂，具有实际应用价值。

参考文献

[1] Zdrazil B, Felix E, Hunter F, et al. The ChEMBL Database in 2023: a drug discovery platform spanning genomics, chemical biology and beyond[J]. Nucleic Acids Research, 2024, 52(D1): D1180–D1192.

[2] Landrum G. RDKit: Open-source cheminformatics[EB/OL]. https://www.rdkit.org/.

[3] Rogers D, Hahn M. Extended-connectivity fingerprints[J]. Journal of Chemical Information and Modeling, 2010, 50(5): 742–754.

[4] Wolpert D H. Stacked generalization[J]. Neural Networks, 1992, 5(2): 241–259.

[5] Yarden Y, Sliwkowski M X. Untangling the ErbB signalling network[J]. Nature Reviews Molecular Cell Biology, 2001, 2(2): 127–137.

[6] Cherkasov A, Muratov E N, Fourches D, et al. QSAR modeling: where have you been? Where are you going to?[J]. Journal of Medicinal Chemistry, 2014, 57(12): 4977–5010.

[7] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825–2830.

[8] Svetnik V, Liaw A, Tong C, et al. Random forest: a classification and regression tool for compound classification and QSAR modeling[J]. Journal of Chemical Information and Computer Sciences, 2003, 43(6): 1947–1958.

A 附录 A：主要超参数配置区间与最优值

为便于复现实验，表7给出主要模型在 RandomizedSearchCV 中的关键搜索空间与最终最优配置。

表 7: 主要模型参数搜索空间与最优结果（节选）

模型	搜索空间（节选）	最优参数（节选）
RF	n_estimators: [300, 900], max_features: [0.2, 0.8]	n_estimators=674, max_features=0.5
HGBT	learning_rate: [0.02, 0.20], max_depth: [3, 10]	learning_rate=0.075, max_depth=7
SVM	C: [0.1, 10], epsilon: [0.01, 0.20]	C=4.65, epsilon=0.019
ET	n_estimators: [300, 900], max_features: [0.2, 0.8]	n_estimators=765, max_features=0.34

B 附录 B：实验环境与可复现说明

实验环境为 Windows 系统，Python 3.12.11（MSYS2 UCRT），核心依赖包括 RDKit、scikit-learn 1.7.1、NumPy 与 Pandas。所有实验脚本按“环节一”至“环节六”顺序执行即可复现本文主要结果。

致谢

感谢指导教师在选题与方法论上的建议，感谢团队成员在数据清洗、模型实验与论文撰写中的分工协作，感谢开源社区提供的 RDKit 与 scikit-learn 等工具支持。本研究得到课程项目平台与计算资源支持，在此一并致谢。